

基于长短期记忆神经网络的二维圆柱绕流 气动力系数预测

刘士杰¹, 胡 波^{2,3}, 张 珍^{1,2,4}, 刘庆宽^{1,2,4}

(1. 石家庄铁道大学土木工程学院, 石家庄 050043;

2. 石家庄铁道大学省部共建交通工程结构力学行为与系统安全国家重点实验室, 石家庄 050043;

3. 石家庄铁道大学工程力学系, 石家庄 050043; 4. 河北省风工程和风能利用工程技术创新中心, 石家庄 050043)

摘 要: 计算流体动力学(Computational Fluid Dynamics, CFD)模拟方法是风工程领域的主要研究方法之一, 但其针对非定常效应显著的流场计算成本通常较高。本文基于长短期记忆(Long short-term memory, LSTM)神经网络框架, 提出了一种二维非定常圆柱绕流的快速时序升阻力预测模型。首先, 基于开源 Tensorflow 库构建 LSTM 网络框架。之后, 基于雷诺数为 300、600 和 1000 时的圆柱绕流数值模拟结果构建训练集和测试集, 并对 LSTM 进行训练, 以学习映射的时间演化和雷诺数的信息。最后, 利用训练好的模型基于雷诺数分布进行内插预测和外插预测。预测结果表明, LSTM 模型能够准确预测雷诺数分布外的二维圆柱绕流的升力和阻力系数, 为非线性流体流动提供了可靠的预测。

关键词: 长短期记忆; 圆柱绕流; 升力系数; 阻力系数; 神经网络

PREDICTION FOR AERODYNAMIC COEFFICIENTS OF TWO-DIMENSIONAL FLOW AROUND A CIRCULAR CYLINDER BASED ON LONG SHORT-TERM MEMORY NEURAL NETWORK

LIU Shi-jie¹, HU Bo^{2,3}, ZHANG Zhen^{1,2,4}, LIU Qing-kuan^{1,2,4}

(1. School of Civil Engineering, Shijiazhuang Tiedao University, Shijiazhuang 050043, China;

2. State Key Laboratory of Mechanical Behavior and System Safety of Traffic Engineering Structures,
Shijiazhuang Tiedao University, Shijiazhuang 050043, China;

3. Department of Engineering Mechanics, Shijiazhuang Tiedao University, Shijiazhuang 050043, China;

4. Innovation Center for Wind Engineering and Wind Energy Technology of Hebei Province, Shijiazhuang 050043, China)

Abstract: Computational Fluid Dynamics (CFD) simulation method is one of the main research methods in the field of wind engineering, but its cost is high for flow fields with significant unsteady effects. This paper performs a rapid time-series lift-drag prediction model of two-dimensional unsteady flow around a circular cylinder based on the Long short-term memory (LSTM) neural network. First, the LSTM framework is constructed based on the open source Tensorflow library. After that, training set and testing set are generated based on the numerical simulation results with Reynolds numbers of 300, 600 and 1000, and the LSTM is trained to learn the time evolution of the mapping and the information of Reynolds number. Finally, the trained model is used to perform interpolation prediction and extrapolation prediction based on the Reynolds number distribution. The prediction results show that the LSTM model can accurately predict the lift and drag coefficients of two-dimensional flow around circular cylinder outside the Reynolds number distribution, and provide a reliable prediction for nonlinear

基金项目: 国家自然科学基金(51778381); 科技冬奥专项(21475402D); 河北省高层次人才项目(冀办[2019]63 号)

通讯作者: 张 珍(1994-), 女, 河南人, 讲师, 博士, 主要从事机器学习在风工程中的应用研究(E-mail: zhangz@stdu.edu.cn).

作者简介: 刘士杰(1998-), 男, 河北人, 硕士生, 主要从事结构抗风和深度学习研究(E-mail: lsj19980123@163.com);

胡 波(1986-), 男, 河北人, 讲师, 博士, 主要从事大跨空间结构和桥梁风荷载研究(E-mail: bohu@stdu.edu.cn);

刘庆宽(1971-), 男, 河北人, 教授, 博士, 主要从事桥梁与结构的风荷载、风致振动与控制研究(E-mail: lqk@stdu.edu.cn).

fluid flow.

Key words: LSTM; flow around circular cylinder; lift coefficient; drag coefficient; neural network

拉索、烟囱、竖井和冷却塔等具有圆形断面的工程结构或构件，往往面临着复杂的流动分离现象，因此，对圆形断面绕流问题的风荷载和风致振动特性的研究至关重要^[1-5]。随着计算机性能的不断提升，计算流体力学(Computational Fluid Dynamics, CFD)技术已经广泛应用于风荷载等相关问题研究^[6]。CFD 技术具有适应性强、应用面广和节省时间等优点，但在一些与时间序列相关的非定常工程应用问题上，依然存在很大局限性。

近年来，深度学习方法在自然语言处理等方面的应用已经取得很大成功。深度学习技术能够学习数据集中蕴含的内在属性，从而缓解过拟合问题以及提高泛化能力^[7-11]。LSTM 作为一种链式网络，已被证明能够很好的预测时序相关问题^[12]。本文旨在通过建立 LSTM 模型，使用 CFD 模拟结果构建训练集和测试集，以预测不同雷诺数二维圆柱绕流充分发展时的升力和阻力系数。其余部分的结构如下：第一节分析了所用 LSTM 框架，第二节阐述了数据集建立和模型训练过程，第三节给出了预测结果分析，第四节对全文进行了总结。

1 LSTM 框架分析

LSTM 具有一种重复神经网络模块的链式形式，是循环神经网络(Recurrent Neural Network, RNN)的一种变体，如图 1 所示。LSTM 单元是 LSTM 模型的一个基本模块，包含输入门 I_t 、遗忘门 F_t 、输出门 O_t 和记忆体 C_t 。LSTM 解决了 RNN 的长期依赖问题和梯度爆炸、梯度消失问题，所以更加稳定和适用。LSTM 单元内部的具体计算公式如式(1)。




图 1 LSTM 示意图

Fig.1 Schematic diagram of LSTM neural network

$$\begin{aligned}
 I_t &= \sigma(W_I \cdot [Y_{t-1}, X_t] + b_I) \\
 F_t &= \sigma(W_F \cdot [Y_{t-1}, X_t] + b_F) \\
 O_t &= \sigma(W_O \cdot [Y_{t-1}, X_t] + b_O) \\
 C'_t &= \tanh(W_C \cdot [Y_{t-1}, X_t] + b_C) \\
 C_t &= F_t \otimes C_{t-1} + I_t \otimes C'_t \\
 Y_t &= O_t \otimes \tanh(C_t)
 \end{aligned} \tag{1}$$

式中： X_t 为当前时刻输入值； Y_{t-1} 为上一时刻输出值； W_I, W_F, W_O, W_C 和 b_I, b_F, b_O, b_C 分别为 LSTM 神经网络的权重和偏置； σ 和 $\tanh$ 为激活函数，定义如下：

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \tag{2}$$

2 数据集建立与模型训练

2.1 数据集建立

本研究所用数据基于开源软件 OpenFOAM^o平台^[13]进行数值模拟，分别对雷诺数为 300、600 和 1000

的二维圆柱绕流进行非定常雷诺时均法(Unsteady Reynolds Average Navier-Stokes, URANS)模拟。计算域平面示意图如图 2 所示, 模拟获得的三种雷诺数的升阻力系数数据如图 3。




图 2 圆柱绕流计算域和边界条件

Fig.2 Computational domain and boundary condition of flow around a circular cylinder




图 3 不同雷诺数的升力和阻力系数

Fig.3 Lift and drag coefficients of different Reynolds numbers

2.2 模型训练

本文共训练 6 个 LSTM 模型, 模型 1~6 分别预测 $Re=300$ 、 $Re=600$ 、 $Re=1000$ 的升力和阻力系数, 每组数据以前 10s 的力系数作为输入, 第 11s 的力系数作为输出, 共构建 9990 个数据。6 个模型的训练集、验证集和测试集所用数据见表 1。根据雷诺数分布不同, 模型 1 和 2 进行单一雷诺数力系数训练和预测, 以雷诺数 300 时 700s~800s 的力系数作为输入, 预测雷诺数 300 时 900s~1000s 的力系数; 模型 3 和 4 进行内插预测, 以雷诺数 300 和 1000 时 800s~900s 的力系数作为输入, 预测雷诺数 600 时 900s~1000s 的力系数; 模型 5 和 6 进行外插预测, 以雷诺数 300 和 600 时 800s~900s 的力系数作为输入, 预测雷诺数 1000 时 900s~1000s 的力系数。

表 1 训练集、验证集、测试集数据

Table 1 Data of Training set, validation set, and testing set

Method of prediction	Training set	Validation set	Testing set
Single Reynolds number Model 1, 2	$Re=300$: 700s~800s	$Re=300$: 800s~900s	$Re=300$: 900s~1000s
Interpolation Reynolds number Model 3, 4	$Re=300, 1000$: 800s~900s	$Re=600$: 800s~900s	$Re=600$: 900s~1000s
Extrapolation Reynolds number Model 5, 6	$Re=300, 600$: 800s~900s	$Re=1000$: 800s~900s	$Re=1000$: 900s~1000s

3 预测结果分析

6 个 LSTM 模型预测结果如图 4，模型训练误差见表 2。由训练结果可知，LSTM 神经网络能够在一定雷诺数范围内有效的预测升力和阻力系数；预测同一雷诺数、不同时间步的升阻力系数效果最好，使用不同雷诺数升阻力系数数据作为输入，进行内插和外插预测效果次之，但均能准确预测。


表 2 模型训练误差
Table 2 Model training errors

模型	雷诺数	系数类别	MSE	RMSE	MAE
1	Single (Re=300)	升力系数	0.000032	0.005617	0.004677
2	Single (Re=300)	阻力系数	0.000000	0.000271	0.000227
3	Interpolation (Re=600)	升力系数	0.005003	0.070735	0.052742
4	Interpolation (Re=600)	阻力系数	0.000008	0.002863	0.002214
5	Extrapolation (Re=1000)	升力系数	0.001092	0.033041	0.027183
6	Extrapolation (Re=1000)	阻力系数	0.000020	0.004495	0.003772

表中 MSE 为均方误差，RMSE 为均方根误差，MAE 为平均绝对误差，见式(3)。

$$\begin{aligned}
 MSE &= \frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2 \\
 RMSE &= \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2} \\
 MAE &= \frac{1}{m} \sum_{i=1}^m |f(x_i) - y_i|
 \end{aligned}
 \tag{3}$$

式中：m 为样本数； y_i 为真实值； $f(x_i)$ 为预测值。






图4 模型预测结果(上:单雷诺数预测;中:内插预测;下:外插预测)

Fig.4 Model prediction results (Upper: single Reynolds number; Middle: interpolation; Lower: extrapolation)

4 结论

本文发展了一种基于长短期记忆神经网络(LSTM)进行二维非定常圆柱绕流的快速时序升阻力预测的方法。LSTM 网络框架基于开源 Tensorflow 库搭建,所用数据基于开源软件 OpenFOAM 的数值模拟结果,分别对雷诺数为 300、600 和 1000 的二维圆柱绕流进行 URANS 模拟。根据雷诺数分布不同,共训练 6 个 LSTM 模型,分别进行单一雷诺数、内插雷诺数和外插雷诺数的升阻力系数预测。

预测结果显示, LSTM 模型对单一雷诺数升阻力系数预测效果最好,基于雷诺数分布的内插和外插预测次之,但都能够准确预测,因此,可以证明 LSTM 模型能够准确预测雷诺数分布内外的二维圆柱绕流的升力和阻力系数,为非线性流体流动提供了可靠的预测。

参考文献:

- [1] Hu Gang, Kwok K C S. Predicting wind pressures around circular cylinders using machine learning techniques[J]. Journal of Wind Engineering and Industrial Aerodynamics, 2020, 198: 104099.
- [2] Jing Haiquan, He Xuhui, Li Hui. Initial condition and damping effects on rain-wind induced cable vibration[J]. Journal of Wind Engineering and Industrial Aerodynamics, 2018, 175: 376-383.
- [3] MacDonald P A, Kwok K C S, Holmes J D. Wind loads on circular storage bins, silos and tanks: I. point pressure measurements on isolated structures[J]. Journal of Wind Engineering and Industrial Aerodynamics, 1988, 31(2-3): 165-187.
- [4] Lupi F, Niemann H-J, Höffer R. A novel spectral method for cross-wind vibrations: Application to 27 full-scale chimneys[J]. Journal of Wind Engineering and Industrial Aerodynamics, 2017, 171: 353-365.
- [5] Ma Wenyong, Liu Qingkuan, Macdonald J H G, et al. The effect of surface roughness on aerodynamic forces and vibrations for a circular cylinder in the critical Reynolds number range[J]. Journal of Wind Engineering and Industrial Aerodynamics, 2019, 187: 61-72.
- [6] Cochran L, Derickson R. A physical modeler's view of computational wind engineering[J]. Journal of Wind Engineering and Industrial Aerodynamics, 2011, 99(4): 139-153.
- [7] Zhang Zhen, Song Xudong, Ye Shuran, et al. Application of deep learning method to Reynolds stress models of channel flow based on reduced-order modeling of DNS data[J]. Journal of Hydrodynamics, 2019, 31(1): 58-65.
- [8] Maulik R, San O. A neural network approach for the blind deconvolution of turbulent flows[J]. Journal of Fluid Mechanics, 2017, 831: 151-181.
- [9] Hu Gang, Liu Lingbo, Tao Dacheng, et al. Deep learning-based investigation of wind pressures on tall building under interference effects[J]. Journal of Wind Engineering and Industrial Aerodynamics, 2020, 201: 104138.
- [10] 谢晨月, 袁泽龙, 王建春, 等. 基于人工神经网络的湍流大涡模拟方法[J]. 力学学报, 2021, 53(1): 1-16.
- [11] 张珍, 叶舒然, 岳杰顺, 等. 基于组合神经网络的雷诺平均湍流模型多次修正方法[J]. 力学学报, 2021, 53(6): 1532-1542.
- [12] Li Wenjie, Laima Shujin, Jin Xiaowei, et al. A novel long short-term memory neural-network-based self-excited force model of limit cycle oscillations of nonlinear flutter for various aerodynamic configurations[J]. Nonlinear Dynamics, 2020, 100(3): 2071-2087.
- [13] Lysenko D A, Ertesvåg I S, Rian K E. Large-eddy simulation of the flow over a circular cylinder at Reynolds number 3900 using the OpenFOAM toolbox[J]. Flow, Turbulence and Combustion, 2012, 89(4): 491-518.