

文章编号:1001-7372(2023)08-0056-10

基于长短期记忆网络的桥梁非定常气动力预测

刘庆宽^{1,2,3}, 刘士杰¹, 张 珍^{*1,2,3}, 周 雪¹, 靖洪森^{1,2,3}

(1. 石家庄铁道大学 土木工程学院, 河北 石家庄 050043; 2. 石家庄铁道大学 省部共建交通工程
结构力学行为与系统安全国家重点实验室, 河北 石家庄 050043; 3. 河北省风工程
和风能利用工程技术创新中心, 河北 石家庄 050043)

摘要:气动力是影响桥梁结构稳定性和安全性的关键因素之一,其演化规律受其自身非定常特性和计算机精度的影响,很难实现长时间预测。准确预测桥梁结构的气动力特性对结构设计和振动控制具有重要意义。风洞试验和数值模拟是目前气动力研究中应用最广泛的方法,但风洞试验成本高,且难以模拟复杂风场条件,数值模拟对计算资源又具有强依赖性。因此,为了实现计算量和计算精度的平衡,利用长短期记忆(Long Short-term Memory, LSTM)网络开发了一种不同风攻角桥梁非定常气动力时序预测模型。该模型以不同风攻角下 $0\sim n$ 时刻的气动力系数为输入,以 $n+1$ 时刻的气动力系数为输出。首先,基于开源Tensorflow库构建LSTM网络框架;其次,基于 3° 、 4° 和 5° 三个风攻角的桥梁主梁非定常气动力数值模拟结果构建训练集和测试集,并进行模型训练;最后,利用训练好的模型基于风攻角分布进行内插和外推预测。在内插预测时,基于风攻角为 3° 和 5° 时的气动力系数构建数据集对模型进行内插训练,对风攻角为 4° 时的气动力系数进行预测。在外推预测时,基于风攻角为 3° 和 4° 时的气动力系数构建数据集对模型进行外推训练,对风攻角为 5° 时的气动力系数进行预测。结果表明:LSTM预测结果与数值模拟结果随时间变化的轨迹、振幅和周期基本一致,验证了所构建模型的预测能力。为了进一步验证模型的泛化性,使用已经训练好的LSTM外推预测模型对风攻角为 0° 和 -3° 时的气动力系数进行预测,结果显示该模型可以较好地预测原始结果。因此,该算法在桥梁结构非定常气动力预测中具有应用潜力,可为工程应用提供技术支持。

关键词:桥梁工程;气动力系数;长短期记忆;风攻角;深度学习

中图分类号:U441.2 **文献标志码:**A

Unsteady Aerodynamic Prediction for Bridges Based on Long Short-term Memory Networks

LIU Qing-kuan^{1,2,3}, LIU Shi-jie¹, ZHANG Zhen^{*1,2,3}, ZHOU Xue¹, JING Hong-miao^{1,2,3}

(1. School of Civil Engineering, Shijiazhuang Tiedao University, Shijiazhuang 050043, Hebei, China;
2. State Key Laboratory of Mechanical Behavior and System Safety of Traffic Engineering Structures,
Shijiazhuang Tiedao University, Shijiazhuang 050043, Hebei, China; 3. Innovation Center for Wind
Engineering and Wind Energy Technology of Hebei Province, Shijiazhuang 050043, Hebei, China)

Abstract: Aerodynamic force affects the stability and safety of bridge structures significantly.

收稿日期:2023-03-29

基金项目:河北省自然科学基金创新研究群体项目(E2022210078);科技冬奥专项(21475402D);河北省高端人才项目(冀办[2019]63号);国家自然科学基金青年科学基金项目(52208494);河北省自然科学基金青年项目(E2021210063);河北省在读研究生创新能力培养项目(CXZZSS2023079)

作者简介:刘庆宽(1971-),男,河北保定人,教授,博士研究生导师,工学博士,E-mail:lqk@stdu.edu.cn。

***通讯作者:**张 珍(1992-),女,河南商丘人,讲师,工学博士,E-mail:zhangz@stdu.edu.cn。

The understanding of its evolution is influenced by its unsteady characteristics and by computer accuracy, making it difficult to achieve long-term predictions. The accurate prediction of the aerodynamic properties of bridge structures is essential for structural design and vibration control. Wind tunnel tests and numerical simulations are currently the most widely used methods in aerodynamic research. However, wind tunnel tests are expensive, simulating complex wind field conditions is difficult, and numerical simulations depend strongly on computational resources. Therefore, to achieve a balance between computational volume and computational accuracy, in this study, an unsteady aerodynamic time-series prediction model for bridges at different angles of attack was developed using a long short-term memory (LSTM) network. For the model, aerodynamic coefficients of 0 to n moments under different wind attack angles were the input and the aerodynamic coefficients of the $n+1$ moments were the output. First, an LSTM network framework was constructed based on the open-source TensorFlow library. Second, training and test sets were constructed based on the numerical simulation results of the unsteady aerodynamic forces on a bridge at three angles of attack (3° , 4° , and 5°), and the models were trained. Finally, in the interpolation prediction, a dataset was constructed from the aerodynamic coefficients at angles of attack of 3° and 5° to train the model, and the aerodynamic coefficient of 4° was predicted. For extrapolation prediction, a dataset was constructed from the aerodynamic coefficients at angles of attack of 3° and 4° to train the model, and the aerodynamic coefficient of 5° was predicted. The results show that the LSTM prediction results are basically consistent with the trajectory, amplitude, and period of the numerical simulation results over time. To verify the generalization of the model further, the trained LSTM extrapolation prediction model was used to predict the aerodynamic coefficients at angles of attack of 0° and 3° . The results show that the model can predict the original results better. Therefore, this algorithm has potential applications in predicting the unsteady aerodynamics of bridge structures and can provide technical support for engineering applications.

Keywords: bridge engineering; aerodynamic coefficient; long short-term memory; wind attack angle; deep learning

Received 29 Mar. 2023

Funding: Innovation Research Group Project of Natural Science Foundation of Hebei Province of China (E2022210078); Science and Technology Winter Olympics Special Project (21475402D); High-end Talents Project of Hebei Province of China ([2019]63); Youth Program of National Natural Science Foundation of China (52208494); Youth Program of Natural Science Foundation of Hebei Province of China (E2021210063); Innovative Capacity Development Grant Program of Postgraduate students of Hebei Province of China (CXZZSS2023079)

* Corresponding author. *E-mail address:* zhangz@stdu.edu.cn.

<https://doi.org/10.19721/j.cnki.1001-7372.2023.08.006>

0 引言

大跨度桥梁越来越倾向于轻柔化发展,但由于风振现象的影响,部分桥梁结构容易受到破坏^[1]。桥梁的风致振动破坏往往涉及多种复杂流动现象,如边界层、湍流和非定常特征等^[2-3]。因此,研究桥梁结构气动力特性是确保桥梁稳定性和耐久性的关

键因素,准确预测桥梁结构的气动力特性对结构设计和振动控制具有重要意义。

目前,桥梁结构气动力特性的研究方法主要包括风洞试验^[4-7]和数值模拟^[8-9]。风洞试验已经为气动力特性的研究积累了大量的数据,但由于气动力非定常特性的复杂性,仍需要针对不同结构及风攻角进行特定的试验^[10]。随着计算机性能的不断提

升,数值模拟方法因其可控的参数和条件被广泛应用,已经成为桥梁结构气动特性研究的重要手段。目前,数值模拟方法主要基于 Navier-Stokes (N-S) 方程来模拟流场,但是在复杂工程设计中应用时,往往面临着计算量和计算精度难以平衡的困境^[11-12]。

随着计算机和大数据方法的发展,机器学习技术^[13-14]因其在解决高维、复杂和非线性问题中的出色表现,逐渐被广泛应用于结构健康监测、建筑材料和风能等工程领域^[15-16]。Wang 等^[17]提出了一种知识增强的深度神经网络用以模拟结构的非线性响应,结果表明神经网络模型既保证了计算精度又提升了计算效率。Zhai 等^[18]建立了一种能够有效识别裂缝的卷积神经网络模型。Huang 等^[19]将反向传播神经网络与本征正交分解方法相结合,提出了可以预测高层建筑表面风压的模型,大大提升了风洞试验的效率。Hu 等^[20]使用多种机器学习方法准确预测了不同雷诺数和不同湍流强度下圆柱周围的风压。Jin 等^[21]提出了一种融合卷积神经网络的数据驱动模型,利用圆柱周围的压力来预测速度,预测结果与数值模拟结果吻合良好。Li 等^[22]针对大跨桥梁的涡振数据进行聚类分析,得到了速度场与涡振模态的关系。李加武等^[23]使用径向基神经网络对桥梁的涡振性能进行预测,结果显示合理优化后的神经网络模型具有高效、高准确率的特点。以上研究表明,机器学习技术凭借其强大的非线性表征能力在系统建模、损伤识别、荷载预测等方面均取得了成功。

桥梁结构的非定常气动力属于非线性动力学问题,其流动演变规律和气动力特性很难被长时间预测,机器学习强大的算法为其气动力时序建模提供了可能,因此如何利用已有高保真数据预测后续时间序列的气动力是目前研究的热点之一。

循环神经网络(Recurrent Neural Network, RNN)^[24]在时间序列数据建模方面有巨大潜力,但对于具有长期时间依赖性的序列,RNN 往往会遇到梯度爆炸、梯度消失等问题^[25]。LSTM(Long Short-term Memory, LSTM)^[26]架构被提出以解决 RNN 的局限性,这种方法使用 LSTM 细胞单元替换 RNN 中的传统神经元,从而解决梯度爆炸和消失的问题。

LSTM 在非定常流动的预测和建模方面已有广泛应用。张珍等^[27]使用 LSTM 网络进行了非定常空化水翼表面压力预测,预测输出与大涡模拟结果吻合较好。Li 等^[28]使用 LSTM 方法将桥面运动

与运动引起的气动力相结合,建立了风桥耦合的降阶模型。Li 等^[29]将 Newmark- β 法融入 LSTM,准确预测了桥梁的颤振响应。Laima 等^[16]使用双向循环神经网络开发了一种频域模型用于预测抖振响应的功率谱,与传统的抖振分析方法相比,训练好的神经网络模型预测精度更高、所需时间更短。以上研究表明,LSTM 能够对非定常流动进行快速、准确的预测和建模。

自然风一般以一定的角度作用于桥面,分为风攻角和风向角^[30],桥梁的气动性能对风攻角十分敏感。风攻角不同,气流经过钝体断面后分离的剪切层厚度也不同^[31]。目前,不同风攻角下的气动力特性研究主要来源于风洞试验和数值模拟^[32-35],针对风攻角进行气动力系数的建模可以提升传统方法的效率。

因此,本研究采用 LSTM 开发了一种桥梁非定常气动力时序预测模型,基于不同风攻角下的非定常气动力数值模拟结果对构建的模型进行训练,并通过内插预测和外推预测验证模型的预测精度和泛化性能。本文研究内容如下:首先概述了 LSTM 模型和本文所使用的气动力预测方法;其次介绍了数值模拟的设置和结果,并介绍了 LSTM 网络训练数据集的构成;然后对模型预测结果进行分析与讨论;最后进行了总结和展望。

1 基于 LSTM 的气动力预测方法

1.1 长短期记忆网络模型

RNN 将时间维度引入网络结构,适用于存在非线性输入输出关系的时序预测,但是当输入数据的序列变长时,反向传播更新参数会导致梯度消失、梯度爆炸的问题。LSTM 能够有效缓解以上问题,更加稳定和使用。

LSTM 模型结构如图 1(a)所示,相比于传统循环神经网络,LSTM 引入了“记忆块”,解决了传统循环神经网络梯度消失、梯度爆炸的问题,从而能够有效处理长期依赖关系,捕捉气动力的非线性和随机性等特征。每个“记忆块”包含输入门、遗忘门、输出门 3 个门限,3 个门限经过 Sigmoid 激活函数,使门限的范围在 0~1 之间,其内部结构如图 1(b)所示。桥梁主梁气动力的非定常效应通过 LSTM 的循环结构和门控机制体现,LSTM 模型能够根据输入的时程数据动态调整输出的时程数据。因此,本文采用 LSTM 来预测作用于桥梁主梁的非线性非定常气动力,具体计算公式如下




图 1 LSTM 模型结构示意图

Fig. 1 Schematic of LSTM Model Structure

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (1)$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (3)$$

$$C_t = f_t \times C_{t-1} + i_t \times \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (4)$$

$$h_t = o_t \times \tanh(C_t) \quad (5)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (6)$$

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (7)$$

式中: i_t 、 f_t 、 o_t 分别为输入门、遗忘门、输出门; C_t 为细胞态, 表征长期记忆; h_t 为记忆体, 表征短期记忆, 属于长期记忆的一部分; W_i 、 W_f 、 W_o 、 W_c 分别为 LSTM 细胞单元的权重矩阵; b_i 、 b_f 、 b_o 、 b_c 分别为 LSTM 细胞单元的偏置矩阵; σ 和 $\tanh$ 均为激活函数。

LSTM 的训练流程主要分为以下几个步骤, 训练流程如图 2 所示。




图 2 LSTM 训练流程

Fig. 2 LSTM Training Flow Chart

(1) 定义网络结构与参数;

(2) 初始化参数;

(3) 读取数据并进行训练;

(4) 验证预测值与真实值误差, 若不满足要求, 则重复(1)~(4)步骤。

1.2 气动力预测方法

由于气动力的后段时程不仅与当前的结果有关, 还与过去的结果有关, 因此利用 LSTM 的记忆效应预测未来时刻的气动力, 以气动力系数前段时程为输入, 以后段时程为输出。假设 $\Phi_F = [C_F^1, C_F^2, \dots, C_F^M, \dots, C_F^N]^T$ 为模拟获得的气动力系数, 选择前 M 个样本点作为训练集, 基于此构建 LSTM 网络升力系数训练集 X_{train}^L 、 Y_{train}^L 和阻力系数训练集 X_{train}^D 、 Y_{train}^D ; 选择 M 到 N




图 3 输入-输出映射关系

Fig. 3 Input-output Mapping Relationship

$$X_{\text{train}}^L = \begin{bmatrix} C_L^1 & C_L^2 & C_L^3 & \dots & C_L^S \\ C_L^2 & C_L^3 & C_L^4 & \dots & C_L^{S+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ C_L^{M-S} & C_L^{M-S+1} & C_L^{M-S+2} & \dots & C_L^{M-1} \end{bmatrix}_{(M-S) \times S} \quad (8)$$

$$Y_{\text{train}}^L = [C_L^{S+1} \ C_L^{S+2} \ C_L^{S+3} \ \dots \ C_L^M]_{1 \times (M-S)}^T \quad (9)$$

$$X_{\text{train}}^D = \begin{bmatrix} C_D^1 & C_D^2 & C_D^3 & \dots & C_D^S \\ C_D^2 & C_D^3 & C_D^4 & \dots & C_D^{S+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ C_D^{M-S} & C_D^{M-S+1} & C_D^{M-S+2} & \dots & C_D^{M-1} \end{bmatrix}_{(M-S) \times S} \quad (10)$$

$$Y_{\text{train}}^D = [C_D^{S+1} \ C_D^{S+2} \ C_D^{S+3} \ \dots \ C_D^M]_{1 \times (M-S)}^T \quad (11)$$

$$X_{\text{test}}^L = \begin{bmatrix} C_L^{M+1} & C_L^{M+2} & C_L^{M+3} & \dots & C_L^{M+S} \\ C_L^{M+2} & C_L^{M+3} & C_L^{M+4} & \dots & C_L^{M+S+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ C_L^{N-S} & C_L^{N-S+1} & C_L^{N-S+2} & \dots & C_L^{N-1} \end{bmatrix}_{(N-S-M) \times S} \quad (12)$$

$$X_{\text{test}}^D = \begin{bmatrix} C_D^{M+1} & C_D^{M+2} & C_D^{M+3} & \dots & C_D^{M+S} \\ C_D^{M+2} & C_D^{M+3} & C_D^{M+4} & \dots & C_D^{M+S+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ C_D^{N-S} & C_D^{N-S+1} & C_D^{N-S+2} & \dots & C_D^{N-1} \end{bmatrix}_{(N-S-M) \times S} \quad (13)$$

式中: N 为气动力系数数据集样本点总个数; M 为气动力系数训练集样本点个数; S 为 LSTM 模型输入时程

步长。

为了保证 LSTM 模型的准确性和鲁棒性, LSTM 模型所选取的超参数如表 1 所示。参考 Zhang 等^[36]和 Wang 等^[37]对于 LSTM 模型输入时程序列长度的选取,对于小样本单变量的时序预测,本研究分别测试了 5、20、40 三种输入时程步长。

表 1 LSTM 模型超参数

Table 1 Hyper-parameters of the LSTM Model

方法	参数		
第 1 层 LSTM	80	80	80
第 2 层 LSTM	120	120	120
输入时程步长	5	20	40
优化器	Adam	Adam	Adam
学习率	0.001	0.001	0.001
批个数	60	60	60
训练轮次	200	200	200

1.3 模型评价指标

选择均方根误差 (Root Mean Square Error, RMSE)、平均绝对误差 (Mean Absolute Error, MAE) 和平均相对误差 (Mean Relative Error, MRE) 来评估模型的精确程度, 计算公式如下

$$S_{\text{RMSE}} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2} \quad (14)$$

$$S_{\text{MAE}} = \frac{1}{m} \sum_{i=1}^m |y_i - f(x_i)| \quad (15)$$

$$S_{\text{MRE}} = \frac{1}{m} \sum_{i=1}^m \frac{|y_i - f(x_i)|}{y_i} \quad (16)$$

式中: m 为样本数; y_i 为真实值; $f(x_i)$ 为预测值。

2 数据集构建

为提升和测试模型的泛化性, 选择不同攻角的气动力系数作为训练和测试数据, 分别计算风攻角为 3° 、 4° 和 5° 时的桥梁结构气动力系数。基于不同风攻角的气动力系数构建内插和外推预测数据集。

2.1 数值模拟设置及结果验证

2.1.1 非定常雷诺时均方法

不可压缩的 Navier-Stokes (N-S) 方程为

$$\frac{\partial u_i}{\partial x_i} = 0 \quad (17)$$

$$\frac{\partial u_i}{\partial t} + \left(u_j \frac{\partial u_i}{\partial x_j} \right) = -\frac{1}{\rho} \frac{\partial p}{\partial x_i} + \nu \frac{\partial^2 u_i}{\partial x_j^2} \quad (18)$$

式中: x_i 、 x_j 为笛卡尔坐标; t 为时间; u_i 为瞬时速度的第 i 个分量; u_j 为瞬时速度的第 j 个分量; p 为瞬时压强; ρ 为密度; ν 为运动黏度。

对 N-S 方程进行时间平均可以得到不可压缩

的非定常雷诺时均 (Unsteady Reynolds Average Navier-Stokes, URANS) 方程

$$\frac{\partial \bar{u}_i}{\partial x_i} = 0 \quad (19)$$

$$\frac{\partial \bar{u}_i}{\partial t} + \left(\bar{u}_j \frac{\partial \bar{u}_i}{\partial x_j} \right) = -\frac{1}{\rho} \frac{\partial \bar{p}}{\partial x_i} + \frac{\partial}{\partial x_j} \left(\nu \frac{\partial^2 \bar{u}_i}{\partial x_j^2} - \overline{u_i u_j} \right) \quad (20)$$

对比式 (18)、(20) 可以看出, 相比于原始 N-S 方程, URANS 方程出现了一个多余项, 即雷诺应力 $\overline{u_i u_j}$, 因此需要引入湍流模型将其封闭, 本研究选取 $k-\omega$ SST 湍流模型。

2.1.2 数值模拟设置

基于开源软件 OpenFOAM 平台进行数值模拟, 分别进行风攻角 (α) 为 3° 、 4° 和 5° 的二维桥梁结构绕流数值模拟。计算域和边界条件如图 4 所示, 圆形计算域直径 $d=1500$ m, 主梁高度 $D=3.5$ m, 宽度 $B=48$ m, 流场的入口定义为速度入口, 流速 $U=1 \text{ m} \cdot \text{s}^{-1}$, $\nu=3.5 \times 10^{-4} \text{ m}^2 \cdot \text{s}^{-1}$, 雷诺数为 $Re=1 \times 10^4$, 出口为零压力梯度流出边界, 桥梁表面为无滑移壁面边界条件, 网格共计约 124 万, 桥梁主梁断面网格加密区域如图 5 所示。




图 4 计算域及边界条件

Fig. 4 Computational Domain and Boundary Conditions




图 5 桥梁主梁断面网格加密区域

Fig. 5 Grid Encryption Area of Bridge Deck Section

2.1.3 数值模拟结果及验证

图 6 为不同风攻角下桥梁主梁断面周围平均压力云图,可以直观地观察主梁断面压力的分布情况。图 7 为不同风攻角下的湍动能(k)云图,反映了风绕过断面时的涡流变化,其周围的涡旋结构显示断面

附近湍流强度更大。由图 6、7 可以看出:不同风攻角下的主梁断面风压分布情况和尾流涡旋结构有着明显的不同。因此,对桥梁结构的气动力进行预测以及分析有助于深入了解流动机理,进而防止桥梁结构破坏。




图 6 不同风攻角下桥梁主梁断面平均压力云图

Fig. 6 Average Pressure Contour of Bridge Deck Section Under Different Angles of Attack




图 7 不同风攻角下桥梁主梁断面湍动能云图

Fig. 7 Turbulence Energy Contour of Bridge Deck Section Under Different Angles of Attack

为确保本数值模拟方法可靠,针对风攻角为 3° 时的数值模拟和风洞试验气动力系数结果进行对比验证,如表 2 所示。风洞试验在石家庄铁道大学 STU-1 风洞的高速试验段进行,试验段宽 2.2 m,高 2 m,最大风速大于 $80 \text{ m} \cdot \text{s}^{-1}$,速度不稳定性、速度场不均匀性和湍流强度均小于 0.2%,方向场不均匀性小于 0.2° [35]。根据相似试验理论,风洞试验雷诺数与数值模拟雷诺数在同一量级,且桥梁主梁断面形状具有清晰的棱角,流体分离点较为固定,雷诺数效应不明显。因此,采用基于缩尺的风洞试验结果可以验证本研究中的数值模拟。结果显示,升力系数相对误差为 11.4%,阻力系数相对误差为 0.5%,证实了本数值模拟方法的准确性。基于此数值模拟方法,进一步计算了风攻角为 4° 和 5° 时的桥梁主梁气动力系数。

表 2 风攻角为 3° 时的气动力系数对比验证

Table 2 Comparative Verification of Aerodynamic Coefficients of 3° Wind Attack Angle

系数类别	数值模拟结果	风洞试验结果	绝对误差	相对误差/%
升力	0.249	0.281	0.032	11.4
阻力	1.303	1.297	0.006	0.5

2.2 气动力数据集构建

内插预测训练集选取风攻角为 3° 和 5° 时的气动力系数,测试集选取风攻角为 4° 时桥梁的气动力系数;外推预测训练集选取风攻角为 3° 和 4° 时桥梁

的气动力系数,测试集选取风攻角为 5° 时桥梁的气动力系数。训练集气动力系数选取区间为 URANS 数值模拟 800~1 900 s 的计算结果,测试集气动力系数选取区间为 URANS 数值模拟 800~2 400 s 的计算结果,构建数据集如表 3 所示。

表 3 训练数据集

Table 3 Training Data Set

预测类别	训练集	测试集
内插预测	$3^\circ, 800 \sim 1\,900 \text{ s}$	$4^\circ, 800 \sim 2\,400 \text{ s}$
	$5^\circ, 800 \sim 1\,900 \text{ s}$	
外推预测	$3^\circ, 800 \sim 1\,900 \text{ s}$	$5^\circ, 800 \sim 2\,400 \text{ s}$
	$4^\circ, 800 \sim 1\,900 \text{ s}$	

3 结果与分析

3.1 输入时程步长对预测结果的影响

不同输入时程步长下气动阻力系数(C_D)预测结果误差及训练用时如表 4 所示。结果表明,使用 LSTM 模型进行内插预测时,输入时程步长分别为 5、20、40 的预测误差接近,使用 LSTM 模型进行外推预测时,预测误差随着输入时程步长的增加而变大。训练模型所用时间随着输入时程步长的增加而变长。综合考虑计算精度和效率,本研究选取的输入时程步长为 5。


3.2 气动力系数内插预测结果

风攻角分布内的升力系数(C_L)和阻力系数(C_D)预测结果如图 8 所示。由图 8 可以看出,LSTM


表 4 不同输入时间步长下预测误差及用时

Table 4 Prediction Error and Time Under Different Input Time Steps

预测类别	输入时程步长	训练轮次	误差/%	训练用时/s
内插预测	5	200	2.2	16
	20	200	2.0	32
	40	200	2.0	65
外推预测	5	200	2.3	13
	20	200	2.7	34
	40	200	4.5	56



(a) 阻力系数预测结果



(b) 升力系数预测结果


图 8 4°风攻角下内插预测结果

Fig. 8 Interpolation Prediction Results at Angle of Attack of 4°


模型预测结果与 URANS 数值模拟结果随时间变化的轨迹、振幅和周期基本一致,证明 LSTM 模型能够较好地预测一定范围内风攻角分布内的桥梁结构气动力系数。

3.3 气动力系数外推预测结果

为了探究模型的外推预测性能,本文采用未充分发展阶段至充分发展阶段的气动力系数作为外推测试区间,风攻角分布外的升力和阻力系数预测结果如图 9 所示。由图 9 可以看出,即使风攻角为 5°时气动力的周期和振幅变化较大,LSTM 模型仍能较好地预测一定范围内风攻角分布外的气动力系数,并且模型对气动力未充分发展阶段到充分发展阶段的过渡区间也能准确预测,由此可见,训练的 LSTM 模型具有一定的泛化性能。



(a) 阻力系数预测结果



(b) 升力系数预测结果

图 9 5°风攻角下外推预测结果

Fig. 9 Extrapolation Prediction Results at Angle of Attack of 5°

为进一步测试 LSTM 模型的泛化性能,使用外推预测模型分别预测风攻角为 0°和-3°时的气动力系数,预测区间涵盖气动力未充分发展阶段和充分发展阶段。其中,0°风攻角下气动力系数预测结果如图 10 所示,预测时间段为 800~2 400 s;-3°风攻角下气动力系数预测结果如图 11 所示,预测时间段为 800~3 000 s。可以看出,外推预测模型能较准确预测不同风攻角下的升力和阻力系数,所训练的模型泛化性较强。但风攻角为-3°时的预测精度低于风攻角为 0°时的预测精度,证明随着外推风攻角范围的增大,模型预测精度在一定程度上也会下降。

3.4 预测误差分析

由式(14)~(16)计算得出 LSTM 模型预测结果误差,如表 5 所示。气动力系数的预测误差是预测值与真实值对比得到的结果,各个风攻角下的预测误差为平行关系,因此,各个风攻角下的预测误差具有可比性。对于内插预测,4°风攻角下的升力系数和阻力系数平均相对误差分别为 0.3%和 2.2%;对于外推预测,5°、0°和-3°三个风攻角下的升力系数平均相对误差分别为 1.6%、5.6%和 5.9%,阻力系数平均相对误差分别为 2.3%、2.9%和 3.6%。经过对比,可以发现内插预测误差最低,外推预测误差随着风攻角范围的推广而增加,但内插预测和外推预测均能较好地重构出桥梁结构非定常气动升力




图 10 0° 风攻角下外推预测结果
Fig. 10 Extrapolation Prediction Results at Angle of Attack of 0°




图 11 -3° 风攻角下外推预测结果
Fig. 11 Extrapolation Prediction Results at Angle of Attack of -3°

和阻力系数,可以证明模型具有较强的泛化性。

4 结 语

(1)机器学习方法为传统风洞试验和数值模拟

表 5 预测结果误差

Table 5 Prediction Result Error

预测方式	风攻角/ ($^\circ$)	系数类别	均方根 误差	平均绝对 误差	平均相对 误差/%
内插 预测	4	升力	0.001	0.001	0.3
		阻力	0.018	0.014	2.2
外推 预测	5	升力	0.006	0.005	1.6
		阻力	0.043	0.035	2.3
	0	升力	0.116	0.092	5.6
		阻力	0.027	0.025	2.9
	-3	升力	0.022	0.022	5.9
		阻力	0.038	0.072	3.6

方法的发展提供了新思路,为充分利用积累的大量试验和模拟数据,实现桥梁结构非定常气动力快速预测,本文基于 LSTM 神经网络构建了一种不同风攻角下的桥梁非定常气动力时序预测模型。

(2)基于不同攻角下的气动力系数 URANS 结果构建数据集,分别进行模型的训练、内插和外推预测。结果表明,LSTM 模型能够准确预测出与数值模拟结果一致的气动力系数,针对不同风攻角也表现出了较好的泛化性能,在保证计算精度的情况下缩短了计算时间,可为桥梁结构气动力提供可靠的预测。

(3)目前的 LSTM 模型数据集均来自亚临界雷诺数分区内的模拟结果,在下一步的工作中,考虑进行跨雷诺数分区的气动力系数预测,进一步提升 LSTM 模型的泛化性,同时考虑将 LSTM 与降阶模型相结合,发展非定常流场时序预测降阶模型,以捕捉时间演化特征并预测未来时刻流场,进一步揭示流动机理。

参考文献:

References:

- [1] 赵 林,李 珂,王昌将,等.大跨桥梁主梁风致稳定性被动气动控制措施综述[J].中国公路学报,2019,32(10):34-48.
ZHAO Lin, LI Ke, WANG Chang-jiang, et al. Review on passive aerodynamic countermeasures on main girders aiming at wind-induced stabilities of long-span bridges [J]. China Journal of Highway and Transport, 2019, 32 (10): 34-48.
- [2] 廖海黎,李明水,马存明,等.桥梁风工程 2020 年度研究进展[J].土木与环境工程学报(中英文),2021,43(增 1):23-30.
LIAO Hai-li, LI Ming-shui, MA Cun-ming, et al. State-of-the-art review of bridge wind engineering in 2020 [J]. Journal of Civil and Environmental Engineering, 2021, 43 (S1): 23-30.
- [3] 葛耀君,赵 林,许 坤.大跨桥梁主梁涡激振动研究进展与思考[J].中国公路学报,2019,32(10):1-18.

- GE Yao-jun, ZHAO Lin, XU Kun. Review and reflection on vortex-induced vibration of main girders of long-span bridges [J]. China Journal of Highway and Transport, 2019, 32 (10): 1-18.
- [4] KASPERSKI M. Specification of the design wind load based on wind tunnel experiments [J]. Journal of Wind Engineering and Industrial Aerodynamics, 2003, 91 (4): 527-541.
- [5] 刘庆宽, 孙一飞, 贾娅娅, 等. 微椭圆截面斜拉索风致振动特性与机理[J]. 中国公路学报, 2019, 32(10): 200-209.
- LIU Qing-kuan, SUN Yi-fei, JIA Ya-ya, et al. Wind-induced vibration characteristics and mechanisms of micro-elliptical section stay cables [J]. China Journal of Highway and Transport, 2019, 32 (10): 200-209.
- [6] 陈文礼, 黄业伟, 孟 昊, 等. 桥塔尾流风作用下吊索尾流致振动模型与参数分析[J]. 中国公路学报, 2022, 35(4): 117-127.
- CHEN Wen-li, HUANG Ye-wei, MENG Hao, et al. Motion model and parameter analysis of flow-induced vibration of suspender in bridge tower wake [J]. China Journal of Highway and Transport, 2022, 35 (4): 117-127.
- [7] MA W, LIU Q, MACDONALD J H G, et al. The effect of surface roughness on aerodynamic forces and vibrations for a circular cylinder in the critical Reynolds number range [J]. Journal of Wind Engineering and Industrial Aerodynamics, 2019, 187: 61-72.
- [8] BLOCKEN B. 50 years of computational wind engineering: Past, present and future [J]. Journal of Wind Engineering and Industrial Aerodynamics, 2014, 129: 69-102.
- [9] STRINGER R M, ZANG J, HILLIS A J. Unsteady RANS computations of flow around a circular cylinder for a wide range of Reynolds numbers [J]. Ocean Engineering, 2014, 87: 1-9.
- [10] JING H, HE X, LI H. Initial condition and damping effects on rain-wind induced cable vibration [J]. Journal of Wind Engineering and Industrial Aerodynamics, 2018, 175: 376-383.
- [11] LYSSENKO D A, ERTESVÅG I S, RIAN K E. Large-eddy simulation of the flow over a circular cylinder at Reynolds number 3 900 using the OpenFOAM toolbox [J]. Flow, Turbulence and Combustion, 2012, 89 (4): 491-518.
- [12] ZHANG Z, SONG X, YE S, et al. Application of deep learning method to Reynolds stress models of channel flow based on reduced-order modeling of DNS data [J]. Journal of Hydrodynamics, 2019, 31 (1): 58-65.
- [13] LECUN Y, BENGIO Y, HINTON G. Deep learning [J]. Nature, 2015, 521 (7553): 436-444.
- [14] HU G, LIU L, TAO D, et al. Deep learning-based investigation of wind pressures on tall building under interference effects [J]. Journal of Wind Engineering and Industrial Aerodynamics, 2020, 201: 104138.
- [15] WU T, SNAIKI R. Applications of machine learning to wind engineering [J]. Frontiers in Built Environment, 2022, 8: 811460.
- [16] LAIMA S, FENG H, LI H, et al. A buffeting-net for buffeting response prediction of full-scale bridges [J]. Engineering Structures, 2023, 275: 115289.
- [17] WANG H, WU T. Knowledge-enhanced deep learning for wind-induced nonlinear structural dynamic analysis [J]. Journal of Structural Engineering, 2020, 146 (11): 04020235.
- [18] ZHAI G, NARAZAKI Y, WANG S, et al. Synthetic data augmentation for pixel-wise steel fatigue crack identification using fully convolutional networks [J]. Smart Structures and Systems, 2022, 29 (1): 237-250.
- [19] HUANG D, HE S, HE X, et al. Prediction of wind loads on high-rise building using a BP neural network combined with POD [J]. Journal of Wind Engineering and Industrial Aerodynamics, 2017, 170: 1-17.
- [20] HU G, KWOK K C S. Predicting wind pressures around circular cylinders using machine learning techniques [J]. Journal of Wind Engineering and Industrial Aerodynamics, 2020, 198: 104099.
- [21] JIN X, CHENG P, CHEN W L, et al. Prediction model of velocity field around circular cylinder over various Reynolds numbers by fusion convolutional neural networks based on pressure on the cylinder [J]. Physics of Fluids, 2018, 30 (4): 047105.
- [22] LI S, LAIMA S, LI H. Cluster analysis of winds and wind-induced vibrations on a long-span bridge based on long-term field monitoring data [J]. Engineering Structures, 2017, 138: 245-259.
- [23] 李加武, 党嘉敏, 吴 拓, 等. 径向基神经网络用于钢-混 II 型梁原始断面涡振性能的预测[J]. 振动工程学报, 2021, 34(1): 1-8.
- LI Jia-wu, DANG Jia-min, WU Tuo, et al. Radial basis function networks used in prediction of vortex-induced vibration of II-shape bridge-decks [J]. Journal of Vibration Engineering, 2021, 34 (1): 1-8.
- [24] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors [J]. Nature, 1986, 323: 533-536.
- [25] BENGIO Y, SIMARD P, FRASCONI P. Learning long-term dependencies with gradient descent is difficult [J]. IEEE Transactions on Neural Networks, 1994, 5 (2): 157-166.
- [26] HOCHREITER S, SCHMIDHUBER J. Long short-term memory [J]. Neural Computation, 1997, 9 (8): 1735-1780.
- [27] 张 珍, 刘庆宽, 王静竹, 等. 基于长短期记忆网络的非定常空化水翼表面压力预测[J]. 中国科学: 物理学、力学、天文学, 2022, 52(10): 104-112.
- ZHANG Zhen, LIU Qing-kuan, WANG Jing-zhu, et al. Unsteady cavitating hydrofoil surface pressure prediction based on long short-term memory network [J]. Science China Physics, Mechanics & Astronomy, 2022, 52 (10): 104-112.
- [28] LI T, WU T, LIU Z. Nonlinear unsteady bridge aerodynamics: Reduced-order modeling based on deep LSTM networks [J]. Journal of Wind Engineering and Industrial Aerodynamics, 2020, 198: 104116.

- [29] LI W, LAIMA S, JIN X, et al. A novel long short-term memory neural-network-based self-excited force model of limit cycle oscillations of nonlinear flutter for various aerodynamic configurations [J]. *Nonlinear Dynamics*, 2020, 100 (3): 2071-2087.
- [30] 王正军,唐俊峰,郭向荣,等. 风攻角对车-桥系统气动特性及耦合振动的影响[J]. *铁道科学与工程学报*, 2022, 19(3): 752-759.
WANG Zheng-jun, TANG Jun-feng, GUO Xiang-rong, et al. Influence of wind attack angle on aerodynamic characteristics and coupled vibration of vehicle-bridge system [J]. *Journal of Railway Science and Engineering*, 2022, 19 (3): 752-759.
- [31] 李永乐,徐昕宇,郭建明,等. 六线双层铁路钢桁桥车桥系统气动特性风洞试验研究[J]. *工程力学*, 2016, 33(4): 130-135.
LI Yong-le, XU Xin-yu, GUO Jian-ming, et al. Wind tunnel tests on aerodynamic characteristics of vehicle-bridge system for six-track double-deck steel-truss railway bridge [J]. *Engineering Mechanics*, 2016, 33 (4): 130-135.
- [32] 刘志文,陈祥艳,陈政清. 山区峡谷桥址地形模型过渡段优化[J]. *中国公路学报*, 2019, 32(10): 266-278.
LIU Zhi-wen, CHEN Xiang-yan, CHEN Zhen-qing. Optimization of transition sections around terrain model at mountain canyon bridge site [J]. *China Journal of Highway and Transport*, 2019, 32 (10): 266-278.
- [33] KOZMAR H, PROCINO L, BORSANI A, et al. Sheltering efficiency of wind barriers on bridges [J]. *Journal of Wind Engineering and Industrial Aerodynamics*, 2012, 107-108: 274-284.
- [34] GUO W, XIA H, KAROUMI R, et al. Aerodynamic effect of wind barriers and running safety of trains on high-speed railway bridges under cross winds [J]. *Wind and Structures*, 2015, 20 (2): 213-236.
- [35] 刘庆宽. 多功能大气边界层风洞的设计与建设[J]. *实验流体力学*, 2011, 25(3): 66-70.
LIU Qing-kuan. Aerodynamic and structure design of multi-function boundary-layer wind tunnel [J]. *Journal of Experiments in Fluid Mechanics*, 2011, 25 (3): 66-70.
- [36] ZHANG X, JI T, XIE F, et al. Unsteady flow prediction from sparse measurements by compressed sensing reduced order modeling [J]. *Computer Methods in Applied Mechanics and Engineering*, 2022, 393: 114800.
- [37] WANG H, ZHANG Y M, MAO J X, et al. A probabilistic approach for short-term prediction of wind gust speed using ensemble learning [J]. *Journal of Wind Engineering and Industrial Aerodynamics*, 2020, 202: 104198.